HADOOP ECOSYSTEM

PENYIMPANAN DAN PENGOLAHAN BIG DATA

152024049 - JULIUS SATRIA AGUNG
152024049 - FADIL M FENEGAR
152024188 - PUTRI AMELINA RAHMAWATI
152024215 - JIHAN NUR ALFIAH

Apa Itu Hadoop?

Hadoop adalah framework Apache yang mendukung penyimpanan dan pemrosesan data berskala besar menggunakan sekumpulan komputer atau cluster

1. **Distributed Storage:** data disimpan pada beberapa komputer.
2. **Parallel Processing:** pekerjaan dapat diproses secara paralel.
3. **Scalability**: kapasitas dapat ditingkatkan dengan menambah node.
4. **Open-source:** dapat digunakan dan dikembangkan secara terbuka.

Cluster: sekumpulan komputer yang bekerja sebagai satu sistem.
Node: satu komputer dalam cluster.

Apa Itu Hadoop Ecosystem?

Hadoop Ecosystem adalah kumpulan komponen yang mendukung berbagai kebutuhan pengelolaan data.

Komponen
HDFS
MapReduce
YARN
Hive
Pig
HBase
Sqoop
Flume
Oozie

Hadoop **menyediakan library dan utilitas dasar yang mendukung komponen inti Hadoop**. Komponen digunakan sesuai kebutuhan masalah big data.

HDFS

Penyimpanan Data Terdistribusi

Hadoop Distributed File System menyimpan **data berskala besar secara terdistribusi pada beberapa node** dalam cluster Hadoop.

01 **NameNode:** mengelola metadata filesystem, seperti lokasi blok data.

02 **DataNode:** menyimpan blok-blok data.

03 **Replication:** membantu menjaga ketersediaan data ketika terjadi kegagalan node.

MapReduce

Distributed Data Processing

MapReduce **mengolah data dalam bentuk batch**, yaitu satu kumpulan data yang diproses sebagai satu pekerjaan.

YARN

Resource Management

YARN(Yet Another Resource Negotiatior) **mengatur sumber daya cluster** agar aplikasi memperoleh kapasitas untuk berjalan.

MapReduce

Distributed Data Processing

01 **Map:** membaca bagian data dan menghasilkan pasangan kunci–nilai.

02 **Shuffle dan Sort:** mengumpulkan hasil yang memiliki kunci sama.

03 **Reduce:** mengolah setiap kelompok menjadi hasil akhir.

YARN

Resource Management

01 **ResourceManager:** membagikan sumber daya untuk aplikasi dalam cluster.

02 **NodeManager:** menjalankan dan memantau container pada setiap node.

03 **ApplicationMaster:** mengoordinasikan pelaksanaan suatu aplikasi.

04 **Container:** alokasi sumber daya, seperti CPU dan RAM, untuk menjalankan tugas.

Hive

Data Warehouse & Query Processing

Melakukan **query dan analisis terhadap data Hadoop menggunakan bahasa SQL-like**, yaitu *HiveQL*.

Keunggulan:

- Mendukung analisis dengan sintaks mirip SQL.
- Memudahkan agregasi dan pengelompokan data.
- Memungkinkan pengguna menganalisis data tanpa menulis Mapper dan Reducer secara manual.

```
SELECT
    district,
    COUNT(*) AS total_vaksinasi
FROM imunisasi
GROUP BY district;
```

*Query menghitung jumlah vaksinasi setiap distrik.

Pig

ETL & Data Transformation

Melakukan **pengolahan serta transformasi data** menggunakan bahasa Pig Latin.

ETL terdiri dari:

- **Extract**: mengambil data dari sumber.
- **Transform:** membersihkan, menyaring, dan mengubah data.
- **Load:** menyimpan hasil pengolahan.

Contoh:
Data mentah yang tidak lengkap diproses untuk menghasilkan data yang siap dianalisis.

HBase

NoSQL Database

Menyimpan dan **mengakses data secara cepat berdasarkan row key.**

Karakteristik:

- Database NoSQL berorientasi column family.
- Berjalan di atas HDFS.
- Mendukung akses baca/tulis record tertentu secara efisien.

Contoh:

Petugas kesehatan ingin menampilkan riwayat imunisasi seorang anak.

Sqoop

Data Ingestion & Integration

mentransfer data massal (bulk data) antara database relasional (RDBMS) seperti MySQL, PostgreSQL, Oracle, dan sistem penyimpanan Hadoop.

Import: membawa data dari database ke lingkungan Hadoop.
Export: mengirim data dari Hadoop ke database.

Flume

Log Data Ingestion

Layanan terdistribusi untuk mengumpulkan, mengagregasi, dan memindahkan data streaming atau log non-relasional berskala besar

Oozie

Workflow Scheduling & Orchestration

Mengatur urutan dan Sistem koordinator dan penjadwal alur kerja (workflow scheduler) untuk mengatur berbagai macam job di dalam ekosistem Hadoop.

Study Case: Registri imunisasi Anak

Penerapan konsep Hadoop Ecosystem untuk mengolah data imunisasi lintas provinsi.

Tujuan:

- Mengetahui cakupan imunisasi setiap kabupaten.
- Menemukan anak yang belum menerima dosis ketiga.
- Menelusuri riwayat imunisasi seorang anak.

Dataset

- 80.137 profil anak
- 112.066 catatan pemberian dosis
- 12 provinsi dan 24 kabupaten
- Tahun kelahiran: 2022–2025

File	Isi
children.csv	Satu baris untuk setiap anak
vaccination_events.csv	Satu baris untuk setiap pemberian dosis

Satu anak hanya memiliki satu profil, tetapi bisa memiliki beberapa catatan dosis. Karena itu, jumlah catatan vaksinasi berbeda dari jumlah anak

Target Analysis

Analisis berfokus pada anak:

01 Lahir tahun 2023.

02 Ditandai sudah waktunya menerima D3.

Eligible	Memenuhi syarat untuk masuk perhitungan
D1 / D2 / D3	Dosis pertama / kedua / ketiga
Status 1 / 0	Sudah menerima / belum menerima

Hive

Ukuran	Perhitungan
Cakupan D3	D3 ÷ total anak × 100%
Putus lanjut D1→D3	(D1 - D3) ÷ D1 × 100%

- Cakupan menggunakan seluruh anak yang memenuhi syarat.
- Putus lanjut menggunakan anak yang sudah menerima D1.
- Jika tidak ada penerima D1, putus lanjut ditampilkan N/A.

python code/demo.py hive

Pig

File	Perhitungan
cohort.csv	jumlah anak dalam kelompok analisis
missed_dose3.csv	jumlah anak belum D3

python code/demo.py pig

HBase

Demo Study Case

Row key	ID anak sebagai kunci pencarian.
Profil	kelompok kolom untuk identitas anak.
History	kelompok kolom untuk riwayat dosis.

```
python code/demo.py hbase --child (ID Anak)
```

Proyeksi Pencapaian

Keunggulan layanan kami terletak pada kualitas, ketepatan waktu, serta kepuasan pelanggan yang selalu menjadi prioritas utama dalam setiap proyek yang kami tangani.

Target Pencapaian

40%

Peningkatan Klien Bisnis

Kami menyediakan berbagai opsi penyesuaian dalam penawaran ini bagi tiap klien

Proyeksi Hasil Projek

60%

Pencapaian Jumlah Klien

Kami menyediakan berbagai opsi penyesuaian dalam penawaran ini bagi tiap klien

Riset dan Analisa Pasar

Keunggulan layanan kami terletak pada kualitas, ketepatan waktu, serta kepuasan pelanggan yang selalu menjadi prioritas utama dalam setiap proyek yang kami tangani.

Kompetitor 1

Thynk Unlimited

67% Bisnis Sukses

Preview **4.7 Rate**

Dengan pendekatan inovatif dan strategis

Kompetitor 2

Studio Shodwe

78% Bisnis Sukses

Preview **4.9 Rate**

Siap mendukung pertumbuhan bisnis

Target Pasar

Umur **20-59**

Gender **Lk & Pr**

Job **Desain**

Hubungi Kami Jika Ada Ingin Menanyakan Info Lebih Lanjut



+123-456-7890
www.reallygreatsite.com
123 Anywhere St., Any City,
ST 12345

20
30

TERIMAKASIH ATAS PERHATIAN

AKHIRI PRESENTASI →

SAMPAI JUMPA NANTI!